

BM25 & Tokenization tiếng Việt

Tài liệu giải thích thuật toán BM25 (Sparse Retrieval) và vai trò của Tokenization tiếng Việt bằng Underthesea trong hệ thống DentalAI.

Tham chiếu mã nguồn: [src/retriever/search.py](#) dòng 92-100 (BM25 init), dòng 126-134 (tokenizer)

1. BM25 là gì?

BM25 (Best Matching 25) là thuật toán xếp hạng văn bản dựa trên tần suất từ khóa, thuộc họ TF-IDF. Nó trả lời câu hỏi: "Tài liệu nào chứa nhiều từ khóa của query nhất, có tính đến độ hiếm của từ?"

Công thức BM25 (Okapi variant)

$$\text{BM25}(Q, D) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

Trong đó:

- $Q = \{q_1, q_2, \dots, q_n\}$: các token của query
- $f(q_i, D)$: tần suất xuất hiện của token q_i trong tài liệu D
- $|D|$: độ dài tài liệu (số token)
- avgdl : độ dài trung bình của tất cả tài liệu
- $k_1 = 1.5$ (mặc định): điều chỉnh mức bão hòa của tần suất
- $b = 0.75$ (mặc định): điều chỉnh ảnh hưởng của độ dài tài liệu

IDF — Inverse Document Frequency

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

- N : tổng số tài liệu (762 trong DentalAI)
- $n(q_i)$: số tài liệu chứa token q_i

Ý nghĩa: từ xuất hiện trong ít tài liệu (hiếm) có IDF cao → được ưu tiên. Từ phổ biến như "và", "là" có IDF thấp → gần như bị loại.

2. Tại sao cần Tokenization tiếng Việt?

Vấn đề

Tiếng Việt là ngôn ngữ **đa âm tiết** — một từ có nghĩa có thể gồm 2-3 âm tiết:

- "niềng răng" = 1 khái niệm, nhưng nếu tách theo dấu cách → 2 token "niềng" + "răng"
- "sâu răng" = 1 bệnh, nhưng tách → "sâu" + "răng" (mất nghĩa: "sâu" có thể là con sâu)

Nếu dùng whitespace tokenization (tách theo dấu cách), BM25 sẽ:

- Tìm "răng" trong tất cả tài liệu → quá nhiều kết quả không liên quan

- Không phân biệt "sâu răng" (bệnh) vs "răng sâu" (mô tả)

Giải pháp: Underthesea Word Tokenizer

Hệ thống sử dụng thư viện **Underthesea** — bộ xử lý ngôn ngữ tự nhiên tiếng Việt:

```
from underthesea import word_tokenize

word_tokenize("niềng răng có đắt không", format="text")
# → "niềng_răng có đắt không"
```

Kết quả: "niềng_răng" trở thành **1 token duy nhất**, BM25 sẽ khớp chính xác với tài liệu có chứa "niềng_răng".

3. Pipeline xử lý trong DentalAI

3.1. Text Normalization

Trước khi tokenize, văn bản được chuẩn hóa:

```
Input: "Chi phí Niềng Răng bao nhiêu?"
Step 1: Lowercase → "chi phí niềng răng bao nhiêu?"
Step 2: Loại bỏ ký tự đặc biệt → "chi phí niềng răng bao nhiêu"
Step 3: Gom khoảng trắng → "chi phí niềng răng bao nhiêu"
```

3.2. Vietnamese Tokenization

```
Input: "chi phí niềng răng bao nhiêu"
Output: ["chi_phí", "niềng_răng", "bao_nhiêu"]
```

Underthesea gộp các cụm từ có nghĩa bằng dấu gạch dưới.

3.3. BM25 Corpus Construction

Khi khởi tạo Retriever, corpus BM25 được xây dựng từ metadata đã enriched:

```
enriched_corpus = [
    f"{title} {section} {summary} {content}"
    for doc in metadata
]
tokenized_corpus = [normalize_and_tokenize(text) for text in enriched_corpus]
bm25 = BM25Okapi(tokenized_corpus)
```

Mỗi tài liệu được biểu diễn bằng danh sách token tiếng Việt. Corpus gồm 762 danh sách token.

4. Ví dụ minh họa

Query: **"chi phí niềng răng"**

Bước 1: Tokenize query

```
["chi_phí", "niềng_răng"]
```

Bước 2: BM25 tính điểm

Tài liệu	Chứa "chi_phí"?	Chứa "niềng_răng"?	BM25 Score
Doc A — "Niềng răng - Chi phí"	Co	Co	Cao
Doc B — "Niềng răng - Tổng quan"	Khong	Co	Trung bình
Doc C — "Sâu răng - Chi phí"	Co	Khong	Trung bình
Doc D — "Chăm sóc răng miệng"	Khong	Khong	0

Doc A chứa **cả hai** token → BM25 score cao nhất.

Nếu không dùng Underthesea (whitespace tokenization)

```
Query tokens: ["chi", "phí", "niềng", "răng"]
```

- "răng" xuất hiện trong hầu hết 762 tài liệu → IDF rất thấp → gần như vô dụng
- "chi" và "phí" tách rời → có thể khớp với tài liệu không liên quan chứa từ "chi tiết" hoặc "phí tổn"

5. So sánh BM25 vs Vector Search (FAISS)

Tiêu chí	BM25 (Sparse)	FAISS (Dense)
Cách hoạt động	Khớp từ khóa chính xác	Tìm vector ngữ nghĩa gần nhất
Thế mạnh	"bảng giá niềng răng" → tìm đúng bài có từ "bảng giá"	"niềng răng có đau không" → hiểu "đau" liên quan đến "cảm giác khó chịu"
Điểm yếu	Không hiểu đồng nghĩa: "giá" vs "chi phí"	Có thể trả về bài đúng chủ đề nhưng sai section
Tốc độ	Rất nhanh (chỉ đếm token)	Nhanh (Inner Product) nhưng cần load model

Đây là lý do hệ thống dùng **Hybrid Search** — kết hợp cả hai qua RRF.