

Multi-Query Expansion

Tài liệu giải thích kỹ thuật mở rộng truy vấn bằng LLM — sinh nhiều biến thể từ đồng nghĩa để tăng recall trong hệ thống tìm kiếm.

Tham chiếu mã nguồn: `src/retriever/search.py` dòng 143-168 (`expand_queries`)

1. Vấn đề: Vocabulary Mismatch

Khi người dùng hỏi "chi phí niềng răng", nhưng tài liệu trong kho dùng từ "bảng giá chỉnh nha", thì:

- **FAISS** (Vector Search): có thể bắt được vì hiểu ngữ nghĩa "chi phí" ~ "bảng giá"
- **BM25** (Keyword Search): **bỏ sót** vì không có từ "chi phí" trong tài liệu

Đây gọi là **Vocabulary Mismatch** — cùng ý nghĩa nhưng dùng từ ngữ khác nhau.

2. Giải pháp: LLM sinh biến thể

Trước khi tìm kiếm, hệ thống dùng LLM sinh thêm 2 câu hỏi tương đương nhưng dùng từ ngữ khác:

Query gốc:

"chi phí niềng răng tổng quan"

Biến thể 1:

"giá chỉnh nha các loại phổ biến hiện nay"

Biến thể 2:

"bảng giá niềng răng bao nhiêu tiền"

Tổng cộng 3 queries được gửi vào Hybrid Search. Kết quả từ cả 3 được cộng điểm RRF → tài liệu xuất hiện ở **nhiều biến thể** được boost tự nhiên.

3. Luồng xử lý

Query gốc

|

v

LLM (EXPAND_QUERY_SYSTEM_PROMPT)

|

— Biến thể 1 (từ đồng nghĩa)

— Biến thể 2 (từ đồng nghĩa)

|

v

[Query gốc, Biến thể 1, Biến thể 2]

|


v

Mỗi query → `_hybrid_score()` → {doc_idx: rrf_score}

|

v

Cộng điểm across 3 queries



Prompt hệ thống

"Bạn là trợ lý mở rộng truy vấn tìm kiếm nha khoa.
Từ câu truy vấn gốc, hãy tạo thêm 2 câu hỏi tương đương
nhưng dùng từ ngữ/từ đồng nghĩa khác.
Giữ nguyên ý nghĩa gốc. Mỗi câu 1 dòng, không đánh số, không giải thích."

Temperature = 0.5 — đủ sáng tạo để sinh từ đồng nghĩa nhưng không quá xa ý gốc.

4. Cross-Query Score Merging

Sau khi mỗi query chạy qua Hybrid Search (FAISS + BM25 + RRF), điểm được cộng lại:

Doc A: query_1=0.012 + query_2=0.010 + query_3=0.011 = 0.033
Doc B: query_1=0.008 + query_2=0.000 + query_3=0.009 = 0.017
Doc C: query_1=0.000 + query_2=0.007 + query_3=0.000 = 0.007

- Doc A xuất hiện ở cả 3 biến thể → **điểm cao nhất** → rất liên quan
- Doc B xuất hiện ở 2/3 → điểm trung bình
- Doc C chỉ xuất hiện ở 1 biến thể → có thể chỉ khớp từ khóa cục bộ

Cơ chế này gọi là **implicit voting** — tài liệu được "bình chọn" bởi nhiều góc nhìn khác nhau.

5. Fallback khi LLM lỗi

Nếu LLM không khả dụng (mất kết nối, timeout), `expand_queries()` trả về chỉ query gốc:

```
except Exception:  
    return [query]
```

Hệ thống vẫn hoạt động bình thường với 1 query, chỉ giảm recall. Thiết kế này đảm bảo **graceful degradation** — lỗi phụ không làm sập hệ thống chính.

6. Tác động đến hiệu năng

Tiêu chí	Không có Expansion	Có Expansion (3 queries)
Recall	Thấp hơn (bỏ sót từ đồng nghĩa)	Cao hơn đáng kể

Tiêu chí	Không có Expansion	Có Expansion (3 queries)
Latency	1x Hybrid Search	3x Hybrid Search + 1 LLM call
Chi phí LLM	0	~0.0003 USD/query (max_tokens=200)
Precision	Cao	Tương đương (RRF loại noise tự nhiên)

Latency tăng khoảng 0.3-0.5s cho LLM call, nhưng Hybrid Search rất nhanh (brute-force 762 docs < 5ms mỗi query) nên tổng latency vẫn chấp nhận được.