

Prompt Engineering — Thiết kế Prompt cho hệ thống RAG Nha khoa

Tài liệu giải thích chiến lược thiết kế prompt trong DentalAI, bao gồm 9 quy tắc cứng của System Instructions, cơ chế Query Rewrite, và Entity Extraction.

Tham chiếu mã nguồn: `src/lib/constants.py` (toàn bộ prompt), `src/agent/chatbot.py` (logic gọi LLM)

1. Tổng quan kiến trúc Prompt

Hệ thống sử dụng 4 LLM call, mỗi call có prompt riêng biệt:

LLM Call	System Prompt	User Template	Temperature
Rewrite Query	REWRITE_SYSTEM_PROMPT	REWRITE_USER_TEMPLATE	0.0 (STRICT)
Extract Category	EXTRACT_CATEGORY_SYSTEM_PROMPT	EXTRACT_CATEGORY_USER_TEMPLATE	0.0 (STRICT)
Expand Queries	EXPAND_QUERY_SYSTEM_PROMPT	(query trực tiếp)	0.5
Answer Stream	AI_SYSTEM_INSTRUCTIONS	AI_USER_PROMPT_TEMPLATE	0.3 (NORMAL)

Tất cả prompt được tập trung trong file `constants.py` — tách biệt hoàn toàn khỏi logic code, để review và chỉnh sửa.

2. System Instructions — 9 Quy tắc cứng

Đây là system prompt cho LLM call cuối cùng (Answer Stream), định nghĩa nhân cách và hành vi:

Persona: "Bạn là một bác sĩ nha khoa chuyên nghiệp người Việt Nam"

Rule 1: Không cảm thán thừa thãi

KHÔNG dùng: "Ồ", "À", "Vâng", "Chào bạn", "Dạ"

CÓ dùng: Câu dẫn nhập ngắn gọn đi thẳng trọng tâm

VD: "Để chăm sóc răng sau khi niềng, bạn cần lưu ý các bước sau:"

Lý do: Chatbot y khoa cần tông chuyên nghiệp, không giống chatbot giải trí.

Rule 2: Strict Grounding (CỐT LỖI)

CHỈ ĐƯỢC PHÉP trả lời dựa trên "Ngữ cảnh nha khoa liên quan" do hệ thống cung cấp.

Đây là quy tắc **chống ảo giác (hallucination)** quan trọng nhất. LLM không được dùng kiến thức tự có — mọi thông tin phải trích từ context do Retriever cung cấp.

Rule 3: Từ chối khi không có dữ liệu

Nếu ngữ cảnh không liên quan → trả đúng 1 câu cố định:
"Hiện tại kho dữ liệu của hệ thống chưa có thông tin cụ thể về vấn đề này.
Bạn nên tham khảo trực tiếp ý kiến của bác sĩ nha khoa để có câu trả lời chính xác nhất."

Câu từ chối được **hard-code** để đảm bảo consistency — LLM không được tự sáng tạo câu từ chối.

Rule 4: Giới hạn chuyên môn

CHỈ trả lời câu hỏi nha khoa. Từ chối lịch sự nếu ngoài phạm vi.

Rule 5: Ngôn ngữ chuyên nghiệp

Trang trọng, khoa học, dễ hiểu — phù hợp bệnh nhân phổ thông lẫn người có hiểu biết y khoa.

Rule 6: Plain text only

KHÔNG dùng Markdown (**, #, []). Trả lời bằng văn bản thuần.

Lý do: Frontend tự xử lý render, tránh markdown lồng nhau gây lỗi hiển thị.

Rule 7: Format liệt kê

Dùng "-" để liệt kê. KHÔNG để dòng trống giữa các mục liệt kê liên tiếp.

Đảm bảo output format nhất quán, dễ parse phía frontend.

Rule 8: Không disclaimer

KHÔNG tự thêm dòng lưu ý cuối — hệ thống tự thêm disclaimer cố định.

Disclaimer được append bởi code (`answer_stream()`), không phải LLM. Tránh trùng lặp.

Rule 9: Chống ám thị chi tiết (QUAN TRỌNG NHẤT)

Nếu câu hỏi chung → **BẮT BUỘC** tổng hợp câu trả lời khái quát.
KHÔNG lấy thông tin thương hiệu cụ thể để trả lời câu hỏi chung.
Nếu ngữ cảnh chỉ có 1 hãng → phải ghi rõ: "Theo quy trình của [Tên Hãng]..."

Giải quyết vấn đề: Khi ngữ cảnh chứa nhiều bài về Invisalign, LLM có xu hướng trình bày quy trình Invisalign như quy trình niềng răng chung. Rule 9 bắt LLM phải nhận diện và ghi rõ nguồn.

3. Query Rewrite — Contextualization

Mục đích

Biến câu hỏi follow-up (thiếu ngữ cảnh) thành câu truy vấn tìm kiếm độc lập:

Lịch sử: "niềng răng là gì?" → "Niềng răng là phương pháp..."
Câu mới: "có đắt không?"
→ Rewrite: "chi phí niềng răng tổng quan các loại phổ biến"

Các quy tắc Rewrite

- 1. **Ghép chủ đề từ câu trước** vào câu follow-up
- 2. **Không thêm chi tiết** (tên răng, vị trí, thương hiệu) nếu người dùng không nhắc
- 3. **Thêm "tổng quan"** cho câu hỏi mang tính tra cứu chung → ưu tiên bài khái quát

Chuẩn bị lịch sử

Lịch sử chat được format khác nhau cho Rewrite vs Answer:

	Rewrite (<code>format_history_for_rewrite</code>)	Answer (<code>format_history_for_prompt</code>)
Số message	6 gần nhất	8 gần nhất
Nội dung assistant	Chỉ dòng đầu, cắt 120 ký tự	Đầy đủ
Mục đích	Đủ để hiểu chủ đề, không thừa	Đủ ngữ cảnh để trả lời tự nhiên

4. Entity Extraction — Phân loại bệnh lý

Mục đích

Trích xuất tên bệnh/dịch vụ từ query để **pre-filter** kết quả tìm kiếm:

"chi phí niềng răng tổng quan" → ["niềng răng"]
"cách chăm sóc răng miệng" → None (quá chung, không filter)

Danh mục

LLM nhận danh sách bệnh/dịch vụ có sẵn trong dataset (`get_available_diseases()`) và trích xuất từ query.
Nếu không khớp → trả về **NONE** → tìm kiếm trên toàn bộ 762 tài liệu.

Tác động

Có category	Không có category
762 → ~60 tài liệu	762 tài liệu
Precision cao, recall giảm nhẹ	Recall tối đa, nhiều noise hơn

5. Temperature Strategy

Giá trị	Tên	Dùng cho	Lý do
0.0	STRICT	Rewrite, Extract	Cần chính xác tuyệt đối, không sáng tạo
0.3	NORMAL	Answer Stream	Đủ tự nhiên, không cứng nhắc, vẫn grounded
0.5	(inline)	Expand Queries	Cần đa dạng từ đồng nghĩa
0.7	CREATIVE	Dự phòng	Chưa sử dụng, dự phòng cho tương lai

Nguyên tắc: Nhiệm vụ càng cần **chính xác** → temperature càng **thấp**. Nhiệm vụ càng cần **đa dạng** → temperature càng **cao**.